

RAPPORT DU DETECTIVE DE DONNÉES — CAFE SALES

Anita Dongmo, Specialist I, Data & IA - Likabo

Le jeu de données contient **10 000 transactions réalisées en 2023**. Après nettoyage, l'analyse montre une activité commerciale relativement stable au cours de l'année, mais révèle surtout que **le volume de ventes ne suffit pas à expliquer la performance commerciale**.

Les produits n'ont pas tous la même contribution au chiffre d'affaires, et le nombre de transactions d'un mois ne permet pas à lui seul d'identifier le mois le plus performant. Enfin, la qualité des données impose de rester prudent sur certaines analyses : les informations de **localisation et de moyen de paiement sont particulièrement incomplètes**.


Points fort des données

1. Le produit le plus vendu n'est pas celui qui génère le plus de chiffre d'affaires

Le **Juice** apparaît dans le plus grand nombre de transactions avec **1 171 transactions**, contre **1 148 pour la Salad**. Pourtant, la Salad génère **17 320** de chiffre d'affaires, soit environ **65 % de plus** que le Juice (**10 509**). Cette différence est particulièrement intéressante car les quantités moyennes sont presque identiques : **3,03 unités pour la Salad contre 3,00 pour le Juice**. La différence vient donc notamment de leur valeur unitaire : la Salad est vendue à 5, contre 3 pour le Juice.

Insight : la popularité d'un produit ne signifie pas nécessairement qu'il est le principal contributeur au chiffre d'affaires.

À vérifier : je comparerais les prix réellement appliqués, les éventuelles promotions et la composition des paniers pour déterminer ce qui explique précisément cet écart.




2. Plus de transactions ne signifie pas nécessairement plus de chiffre d'affaires

Octobre est le mois qui compte le plus de transactions avec **838 ventes**, mais son chiffre d'affaires est de **7 302**. À l'inverse, **juin** réalise le chiffre d'affaires mensuel le plus élevé, avec **7 350**, malgré

seulement **818 transactions**. Le montant moyen par transaction est également légèrement supérieur en juin (**9,01**) à celui d'octobre (**8,73**).

Insight : *le nombre de transactions ne suffit donc pas à mesurer la performance d'un mois ; la valeur des transactions réalisées doit également être prise en compte.*



À vérifier : je rechercherais des informations sur les promotions, les changements de prix, les événements particuliers ou la composition des commandes pendant ces mois.

3. Les clients achètent presque les mêmes quantités, mais la valeur des produits change fortement

La quantité moyenne par transaction est remarquablement stable : elle varie seulement de **2,97** à **3,05 unités** selon les huit produits. Pourtant, le chiffre d'affaires généré varie fortement : **17 320 pour la Salad** contre seulement **3 223 pour le Cookie**. Par exemple, Salad et Cookie présentent des quantités moyennes très proches (**3,03 contre 2,97**), alors que leurs prix unitaires sont respectivement de **5 et 1**.

Insight : *dans ce jeu de données, les différences de chiffre d'affaires semblent davantage liées à la valeur unitaire des produits qu'à la quantité moyenne achetée.*

À vérifier : j'analyserais les prix unitaires transaction par transaction ainsi que les remises éventuelles afin de confirmer leur influence sur le chiffre d'affaires.

3 questions encore ouvertes

1. Pourquoi les quantités moyennes sont-elles presque exactement égales à 3 pour tous les produits ?

Cette régularité pourrait correspondre à un comportement réel, mais aussi à une règle dans la génération ou la collecte des données.

2. Pourquoi les données de localisation et de paiement sont-elles aussi incomplètes ?

Après standardisation, environ **39,6 % des informations de localisation** et **31,8 % des informations de paiement** sont non exploitables. Il faudrait comprendre si ces champs étaient facultatifs ou si les données ont été perdues lors de la collecte.

3. Pourquoi certaines données numériques peuvent-elles être parfaitement reconstituées ?

Lorsque Quantity, Price Per Unit et Total Spent sont disponibles, la relation $\text{Total Spent} =$

Quantity × Price Per Unit est cohérente. Il serait intéressant de savoir si cette règle est garantie par le système source.

Conclusion

L'histoire principale du dataset est donc la suivante : le volume de ventes ne raconte pas à lui seul la performance commerciale. La valeur des produits et celle des transactions jouent un rôle important, tandis que certaines limites de qualité des données empêchent encore d'expliquer complètement les comportements observés.

Les résultats constituent des **constats, et non des relations causales** : des données complémentaires et un échange avec la personne responsable de la collecte seraient nécessaires pour confirmer les hypothèses.